

检索增强生成技术在企业智能客服中的应用与实践

作者：王芳, 杨晓峰, 周雨薇

摘要

企业智能客服系统面临知识更新不及时和幻觉回答两大痛点。本文提出基于检索增强生成 (RAG) 的企业智能客服解决方案。系统架构包含文档解析、文本分块、向量化 (BGE-Large-ZH)、混合检索 (向量+BM25, RRF 融合) 和大语言模型生成 (Qwen-72B) 五个核心模块。在某电商平台的实际部署中, 系统回答准确率从 72% 提升至 93%, 平均响应时间 1.8 秒。知识库支持热更新, 新增文档后 5 分钟内即可被检索到。

1. 问题背景

传统智能客服系统主要基于 FAQ 匹配或小模型对话, 存在三个核心问题: 知识覆盖不全、知识更新滞后、幻觉回答。新产品上线后, 客服系统的知识库需要人工更新, 周期长达数天; 基于大模型的客服可能编造不存在的政策或优惠信息, 导致用户投诉。

2. 系统架构

RAG 客服系统的核心流程为: 用户提问 → 查询改写 (LLM 增强) → 混合检索 (向量+BM25) → 上下文组装 (Top-K 拼接) → LLM 生成回答 → 答案质量评估。文档处理流程为: 原始文档 → 格式解析 (PDF/Word/HTML) → 文本分块 (512 tokens, 重叠 64 tokens) → 向量化 → 写入向量库。

3. 混合检索策略

纯向量检索在处理精确匹配 (如订单号、政策条款编号) 时表现不佳; 纯 BM25 检索在语义相似但用词不同的场景下容易遗漏。混合检索采用 RRF 融合两路结果, 融合公式为 $score(d) = 1/(60+rank_vector(d)) + 1/(60+rank_bm25(d))$ 。实验表明, 混合检索的 MRR 比纯向量检索提升 23%, 比纯 BM25 提升 18%。

4. 部署效果

系统在某大型电商平台部署 3 个月后的运营数据: 日均处理咨询 12 万条, 回答准确率 93%, 用户满意度 4.6/5.0, 平均响应时间 1.8 秒。相比原 FAQ 系统: 准确率提升 21 个百分点, 知识更新延迟从 3 天缩短至 5 分钟, 客服人工介入率从 35% 降至 15%。