

中文文本分类与情感分析技术发展综述

作者：黄丽, 徐建华, 郑文博

摘要

中文文本分类是自然语言处理的基础任务之一，广泛应用于舆情监控、垃圾邮件过滤、意图识别等场景。本文综述了中文文本分类技术的演进路径：从基于 TF-IDF + SVM 的传统方法，到以 TextCNN、BiLSTM、BERT 为代表的深度学习方法，再到基于大语言模型的少样本学习方法。在情感分析任务中，基于 GPT-4 的少样本学习在 FewCLUE 基准上已接近全监督方法的 95% 性能。

1. 引言

中文文本分类面临的独特挑战包括：分词歧义——中文没有天然的词边界；字符编码多样性——简繁体、全半角、emoji 需要统一处理；语义复杂性——中文一词多义现象普遍。这些特点使得中文文本分类需要特别关注分词策略和上下文理解。

2. 传统方法

传统中文文本分类流程为：分词 (jieba/HanLP) → 去停用词 → 特征提取 (TF-IDF/Word2Vec) → 分类器训练 (SVM/随机森林)。在 THUCTC 中文文本分类数据集上，TF-IDF + LinearSVM 的基线准确率为 91.2%。朴素贝叶斯在短文本分类中表现良好，准确率 87.5%。

3. 深度学习方法

TextCNN 利用多尺度卷积核捕获不同长度的 n-gram 特征，在中文新闻分类上达到 95.8%。BiLSTM+Attention 通过注意力机制聚焦关键语义信息，在中文情感分析上达到 93.2%。BERT-wwm (中文全词掩码预训练) 在多个分类数据集上达到 SOTA：ChnSentiCorp 情感分类 96.1%、TNEWS 新闻分类 97.8%。

4. 大模型时代

GPT-4 通过精心设计的 Prompt，在零样本中文分类任务上达到了 89.3% 的准确率，接近 BERT-wwm 的全监督水平。Chain-of-Thought 推理可以进一步提升复杂分类任务的性能。领域微调 (如 LoRA 微调 Qwen-72B) 在特定领域 (医疗、法律) 可达到 98% 以上的分类准确率。